

WYDZIAŁ FIZYKI I INFORMATYKI STOSOWANEJ



SYSTEMY RÓWNOLEGŁE I ROZPROSZONE
Drzewa wszystkich najkrótszych ścieżek
- algorytm Dijkstra'y
Aplikacja równoległa MPI

Arkadiusz Kasprzak
Aleksandra Poręba

21 kwietnia 2020

Spis treści

1	Budowa projektu	3
1.1	Podział na komponenty	3
1.2	Klasy w projekcie	4
2	Działanie projektu	5
2.1	Inicjalizacja	5
2.2	Implementacja i zakończenie algorytmu	10
2.3	Zastosowane funkcjonalności MPI	14
3	Testy projektu	14


1 Budowa projektu

W tej części dokumentacji opisana została budowa przygotowanego projektu - zarówno jeśli chodzi o podział projektu na komponenty (biblioteki), jak i na poszczególne klasy. Nie jest to natomiast dokumentacja kodu - ta została przygotowana odrębnie, w postaci zbioru dokumentów HTML, przy pomocy narzędzia *Doxygen*.

1.1 Podział na komponenty

Projekt podzielony został na trzy główne komponenty:

- **DijkstraCommon** - biblioteka statyczna zawierająca klasy oraz funkcje współdzielone przez pozostałe dwa komponenty. W jej skład wchodzi klasy odpowiedzialne za: zapis wyników obliczeń, walidację danych podanych przez użytkownika, przechowywanie danych na temat przetwarzanego grafu i jego poszczególnych wierzchołków czy przetwarzanie argumentów linii poleceń. Zawiera również klasę **DijkstraAlgorithmBackend** stanowiącą szkielet implementowanego algorytmu.
- **DijkstraSerial** - implementacja algorytmu bez użycia protokołu MPI, czyli w formie klasycznego algorytmu szeregowego. Komponent ten został dołączony do projektu jako punkt odniesienia w procesie testowania wydajności implementacji równoległej. Zawiera funkcję **main**.
- **DijkstraMPI** - implementacja algorytmu używająca protokołu MPI. Jest to jedyny komponent projektu używający tej biblioteki. Zawiera funkcję **main**.



Rysunek 1: Komponenty wchodzące w skład projektu wraz z wzajemnymi zależnościami.

Zależności między poszczególnymi komponentami przedstawia rysunek 1. Na niebiesko oznaczone zostały komponenty produkujące plik wykonywalny, na czerwono natomiast biblioteki. Każdy z komponentów znajduje się w osobnym katalogu o nazwie odpowiadającej nazwie komponentu.

1.2 Klasy w projekcie

TODO:Wtorek

2 Działanie projektu


W tej części dokumentacji omówiony zostanie sposób działania implementacji algorytmu Dijkstra'y wykorzystującej protokół MPI. Algorytm składa się z trzech głównych części:

- inicjalizacja - podział danych wejściowych na części, walidacja, rozesłanie danych do poszczególnych procesów
- obliczenie odległości i ścieżek (algorytm Dijkstra'y)
- zapisanie wyników do pliku i zakończenie działania programu

2.1 Inicjalizacja

Pierwsza część programu składa się z kilku mniejszych etapów. Na początku ma miejsce standardowa inicjalizacja protokołu MPI oraz przypisanie każdemu z procesów rangi. Kolejnym etapem jest utworzenie klasy odpowiedzialnej za wyświetlanie informacji o przebiegu programu na standardowe wyjście. W dalszej kolejności przetwarzane i walidowane są dane wejściowe - numer wierzchołka stanowiącego źródło oraz ścieżka do pliku z danymi wejściowymi. W przypadku, gdy dane są niepoprawne, program kończy działanie wyświetlając odpowiedni komunikat.

Następnie odbywa się przede wszystkim podział danych wejściowych na części i rozesłanie ich do poszczególnych procesów. Program przyjmuje informacje na temat przetwarzanego grafu w postaci tzw. **macierzy sąsiedztwa**. W i -tym rzędzie i j -tej kolumnie takiej macierzy znajduje się waga przypisana do krawędzi łączącej wierzchołek i z wierzchołkiem j . W przypadku braku krawędzi waga wynosi 0. Rysunek 2 przedstawia przykład tego typu reprezentacji wraz z odpowiadającym jej grafem.



Rysunek 2: Przykładowa macierz sąsiedztwa wraz z odpowiadającym jej grafem skierowanym.

Macierz sąsiedztwa wczytywana jest z pliku z danymi wejściowymi przez proces główny (proces `root` o identyfikatorze 0). Proces ten dokonuje podziału macierzy na części zgodnie z ilością procesów biorących udział w wykonaniu algorytmu. Każdy z procesów otrzymuje k kolumn oryginalnej macierzy w formie ciągłego obszaru pamięci - przykładowy podział dla grafu o 5 wierzchołkach i 3 procesów przedstawia rysunek 3.

Algorytm podziału jest prosty. Dana jest macierz o n kolumnach i m procesów. Najpierw każdemu z procesów przypisywane jest:


$$a = \left\lfloor \frac{n}{m} \right\rfloor \quad (1)$$

kolumn - w przypadku $n = 5$ i $m = 3$ każdy proces otrzymuje domyślnie jedną kolumnę. Ilość pozostałych kolumn dana jest zależnością:

$$k = n \bmod m \quad (2)$$

W analizowanym przykładzie jest to $k = 2$. Kolumny te rozdzielane są po jednej pomiędzy k pierwszych (zgodnie z numeracją nadaną przez MPI) procesów. Ostatecznie w omawianym przykładzie proces zerowy i pierwszy

otrzymują po dwie kolumny, proces drugi otrzymuje natomiast tylko jedną kolumnę.



Rysunek 3: Przykładowy podział macierzy sąsiedztwa reprezentującej graf o 5 wierzchołkach. W wykonaniu algorytmu biorą udział 3 procesy.

Kolumny przypisywane są każdemu procesowi po kolei, tzn. proces 0 otrzymuje x_0 pierwszych kolumn macierzy, proces 1 kolejne x_1 itd. Zbiór kolumn reprezentowany jest za pomocą jednowymiarowej tablicy - ułożone są w niej kolejno dane z pierwszej, drugiej itd. kolumny.

Po dokonaniu przez proces `root` podziału, do każdego z procesów wysyłane są trzy informacje:

- całkowita liczba wierzchołków w przetwarzanym grafie - wysyłanie odbywa się za pomocą operacji kolektywnej `MPI_Bcast`

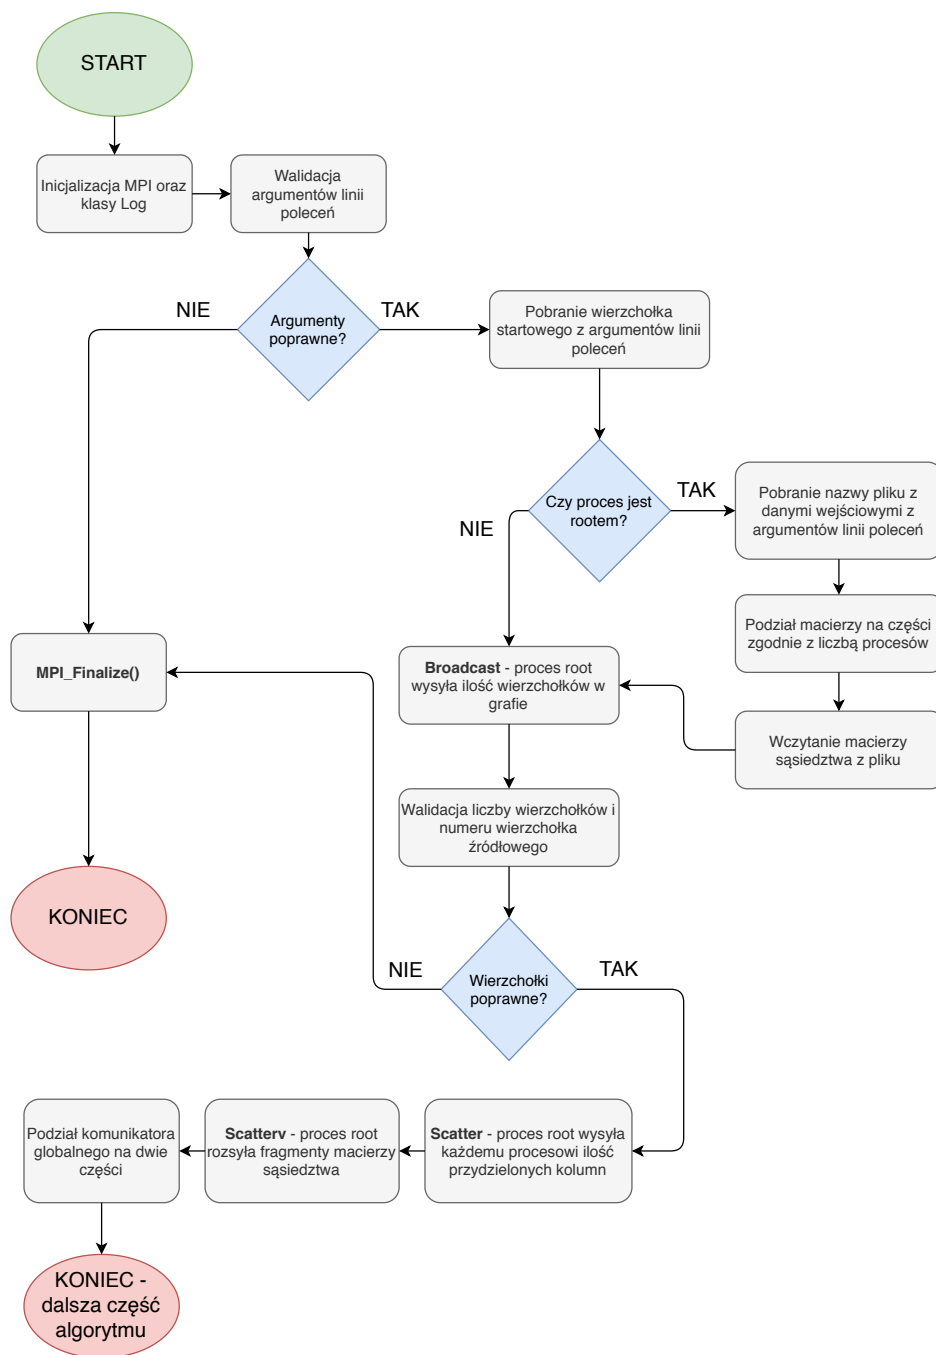
- ilość kolumn macierzy sąsiedztwa, jaka każdy z procesów będzie musiał obsłużyć. Informacja ta jest w tym momencie potrzebna, ponieważ każdy z procesów musi przygotować sobie odpowiednio duży bufor na dane z samej macierzy. Wysyłanie tej informacji odbywa się za pomocą operacji `MPI_Scatter`, ponieważ każdy z procesów otrzymuje swoją indywidualną informację.
- zawartość kolumn macierzy sąsiedztwa, które będą przetwarzane przez dany proces. Wysyłanie tej informacji odbywa się za pomocą funkcji `MPI_Scatterv`, ponieważ jest ona w stanie obsłużyć wysyłanie innej ilości danych do każdego z procesów.

Po zakończeniu wysyłania danych następuje podział procesów na dwie grupy: procesy które otrzymały przynajmniej jedną kolumnę oraz takie, które nie otrzymały żadnej (ma to miejsce, gdy do wykonania algorytmu przydzielone zostaje więcej procesów, niż przetwarzany graf posiada wierzchołków). W tym celu za pomocą operacji `MPI_Comm_split` komunikator globalny dzielony jest na dwa komunikatory. Kryterium podziału stanowi tutaj właśnie sprawdzenie, czy procesowi zostały przydzielone kolumny macierzy do obsługi (`numberOfColumnsToHandle > 0`). Pozwala to wykluczyć nadmiarowe procesy z dalszego przebiegu algorytmu.

Przebieg procesu inicjalizacji jest komunikowany użytkownikowi - na standardowym wyjściu pojawiają się odpowiednie informacje. Poniżej zamieszczono przykład takich informacji wygenerowany dla przykładu widocznego na rysunku 3:

```
[Process 0] This process will handle 2 vertices in range [0 , 1]
[Process 1] This process will handle 2 vertices in range [2 , 3]
[Process 2] This process will handle 1 vertices in range [4 , 4]
...
```

Rysunek 4 przedstawia **schemat blokowy** ilustrujący przebieg procesu inicjalizacji.



Rysunek 4: Schemat blokowy ilustrujący przebieg procesu inicjalizacji.

2.2 Implementacja i zakończenie algorytmu

Początek właściwej części programu stanowi sprawdzenie, czy danemu procesowi przydzielone zostały wierzchołki grafu (czyli kolumny macierzy sąsiedztwa) do przetworzenia. Jeśli nie, to taki proces nie bierze udziału w dalszym wykonaniu algorytmu - następuje dealokacja utworzonego komunikatora i zakończenie działania. W przeciwnym wypadku proces przystępuje do realizacji algorytmu.

Implementacja algorytmu Dijkstra'y za pomocą protokołu MPI nie różni się w sposób znaczący od klasycznej implementacji szeregowej. Każdy z procesów obsługuje dwie tablice:

- tablica odległości (kosztów) od wierzchołka źródłowego do każdego z wierzchołków w grafie
- tablica poprzedników każdego z wierzchołków - służy do odtworzenia najkrótszych ścieżek między wierzchołkami

oraz zbiór obsługiwanych wierzchołków (często nazywany klastrem). Początkowo zbiór ten jest pusty, tablica kosztów zainicjalizowana jest nieskończonościami, a tablica poprzedników wartościami -1. Różnica w stosunku to szeregowej wersji algorytmu jest taka, że w przypadku implementacji równoległej każdy z procesów przechowuje **fragmenty tych tablic** odpowiadające przydzielonym im procesom.

W procesie obsługującym wierzchołek źródłowy jego wpis w tablicy kosztów ustawiany jest na wartość 0. Następnie, dopóki wszystkie wierzchołki nie zostały przetworzone, wykonywany jest w pętli algorytm:

- każdy proces wybiera spośród przydzielonych mu wierzchołków taki, który nie został jeszcze dodany do zbioru wierzchołków obsługiwanych i którego wartość w tablicy kosztów jest najmniejsza
- za pomocą operacji `MPI_Allreduce` wybierany jest wierzchołek o globalnie najniższej wartości kosztu (czyli najlepszy spośród najlepszych z każdego procesu)
- jeśli nie został wyznaczony taki wierzchołek, to następuje wyjście z pętli i zakończenie algorytmu
- w przeciwnym razie wierzchołek zostaje dodany do zbioru wierzchołków przetworzonych (w każdym procesie zbiór ten jest przechowywany osobno, w całości)

- dla każdego nieprzetworzonego sąsiada wyznaczonego wierzchołka dokonywana jest aktualizacja w tablicy kosztów i poprzedników (wybrany wierzchołek staje się poprzednikiem swoich sąsiadów), jeśli nowy koszt okazuje się niższy od dotychczasowego

Po zakończeniu działania algorytmu fragmenty tablic kosztów i poprzedników są łączone w całość za pomocą operacji `MPI_Gatherv`. Proces `root` wyznacza ścieżki z wierzchołka źródłowego do każdego wierzchołka w grafie i zapisuje wyniki do pliku. Następnie wyświetlany jest czas działania algorytmu. Ostatnim krokiem jest zwolnienie utworzonego wcześniej komunikatora, wywołanie operacji `MPI_Finalize` i zakończenie działania programu.


W kilku miejscach w programie tworzona jest zmienna zawierająca aktualny czas. Pod koniec działania, proces `root` zbiera te informacje i wyświetla czas wykonywania się każdej z trzech części algorytmu:

```
[Process 0] Total elapsed time: 0.0298846s  
[Process 0] Setup took: 0.0260188s  
[Process 0] Algorithm took: 0.0020106s  
[Process 0] Printing solution took: 0.0018552s
```

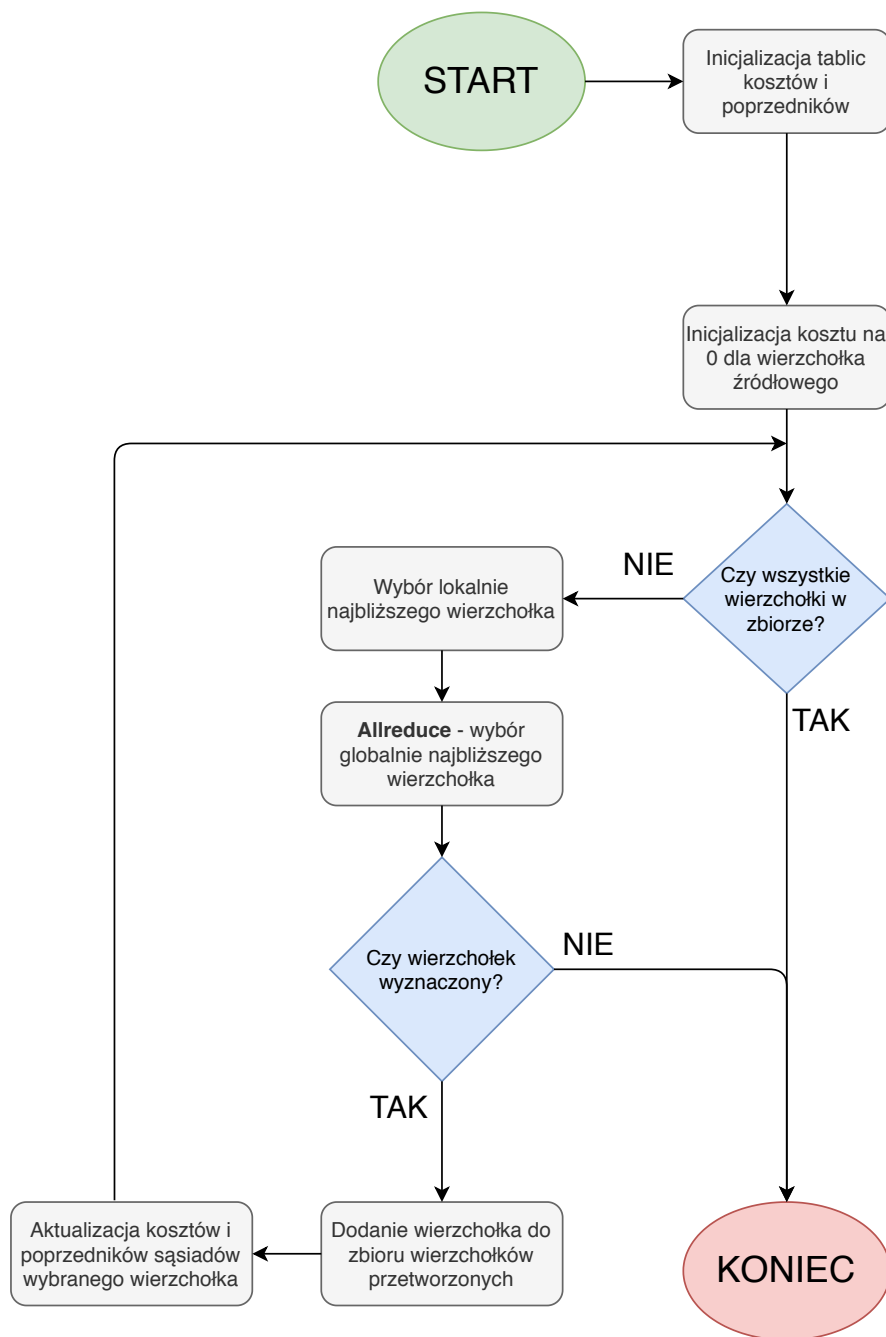
Wyświetlane są wyniki pomiarów dokonanych jedynie w procesie głównym - wyniki z pozostałych procesów są pomijane. Pomiar wykonywany jest z użyciem biblioteki `chrono` z C++11.

Rysunek 5 przedstawia schemat blokowy ilustrujący przebieg działania algorytmu po inicjalizacji. Kolorem fioletowym oznaczony został blok związany z główną pętlą algorytmu Dijkstra'y. Schemat ten nie zawiera szczegółów jej działania.

Rysunek 6 przedstawia schemat blokowy ilustrujący działania głównej pętli algorytmu Dijkstra'y. Schemat ten stanowi rozwinięcie fioletowego bloku z rysunku 5.



Rysunek 5: Schemat blokowy ilustrujący przebieg głównej części programu wraz z zapisaniem wyników i zakończeniem. Schemat nie zawiera implementacji algorytmu Dijkstra'y.



Rysunek 6: Schemat blokowy ilustrujący przebieg głównej pętli algorytmu Dijkstra'y.

2.3 Zastosowane funkcjonalności MPI

TODO:Wtorek W ramach projektu zastosowane zostały następujące funkcjonalności MPI:

- operacja kolektywna `MPI_Bcast`
- operacja kolektywna `MPI_Scatter`
- operacja `MPI_Scatterv`
- operacja `MPI_Gatherv`
- operacja `MPI_Allreduce`
- tworzenie nowego komunikatora za pomocą `MPI_Comm_split`

3 Testy projektu

TODO:Wtorek